

# Л6 Дисперсійний аналіз. 1

## Однофакторна модель

6

Дисперсійний аналіз передбачає значну кількість задач математичної статистики, в яких аналізується вплив різних факторів на остаточний результат.

Зараз розглянемо найпростішу модель, в якій перевіряється гіпотеза про вплив одного фактора.

Нехай маємо  $k$  незалежних вибірок

$$(\xi_{11}, \xi_{12}, \dots, \xi_{1n_1}) \in \Phi_{\alpha_1, \sigma^2}$$

$$(\xi_{21}, \xi_{22}, \dots, \xi_{2n_2}) \in \Phi_{\alpha_2, \sigma^2}$$

.....

$$(\xi_{k1}, \xi_{k2}, \dots, \xi_{kn_k}) \in \Phi_{\alpha_k, \sigma^2}$$

Всі параметри  $\alpha_1, \dots, \alpha_k, \sigma^2$  невідомі.

Перевіряється гіпотеза

$$H_1: \alpha_1 = \alpha_2 = \dots = \alpha_k,$$

$$H_2: \text{існують індекси } i \neq j \text{ такі, що } \alpha_i \neq \alpha_j.$$

Це задача може виникнути, наприклад, в такій ситуації. Неважко  $k$  станках здійснюється виготовлення однакових деталей. Для кожної виготовленої деталі вимірюється якийсь параметр, наприклад, діаметр. Цей параметр є випадковою величиною через неминучі відхилення від стандарту.

Таким чином отримуємо  $k$  вибірок. Перебачається, що на  $i$ -му станку виготовляється  $n_i$  деталей. Гіпотеза  $H_1$  стверджує, що не має значення на якому станку виготовлена деталь, фактур станка не відіграє жодної ролі.

Це відповідає тому, що середні значення (2) не усіх вибірок співпадають. Гіпотеза, що конкурує з  $H_1$  вказує на присутність систематичних відхилень зовнішніх станків.

Далі намітити такі: будемо будувати із систематичних відхилень величину, яка за умови справедливості  $H_1$  розподілена за законом Фішера з віднобраним числом ступенів свободи.

В результаті це викликає розв'язок.

Позначимо

$$N = \sum_{i=1}^k n_i, \quad \bar{\xi}_i = \frac{1}{n_i} \sum_{j=1}^{n_i} \xi_{ij}, \quad \bar{\xi} = \frac{1}{N} \sum_{i=1}^k \sum_{j=1}^{n_i} \xi_{ij}.$$

Теорема. Якщо правильна гіпотеза  $H_1$ , то

$$\frac{(N-k) \sum_{i=1}^k n_i (\bar{\xi}_i - \bar{\xi})^2}{(k-1) \sum_{i=1}^k \sum_{j=1}^{n_i} (\xi_{ij} - \bar{\xi}_i)^2} \in F_{k-1, N-k}.$$

Доведення. Триматимемо на думку те, що нам відомі всі параметри  $\alpha_1, \dots, \alpha_k, \sigma^2$ , і застосуємо до кожного систематичного відхилення стандартізацію. Нехай

$$\eta_{ij} = \frac{\xi_{ij} - \alpha_i}{\sigma} \in \Phi_{0,1}, i=1, \dots, k, j=1, \dots, n_i,$$

$$\bar{\eta}_i = \frac{1}{n_i} \sum_{j=1}^{n_i} \eta_{ij}.$$

Замітимо вираз зовнішньої дисперсії, побудованої за  $i$ -ю вибіркою із стандартизованих систематичних відхилень:



$$\frac{1}{n_i} \sum_{j=1}^{n_i} (\eta_{ij} - \bar{\eta}_i)^2 = \frac{1}{n_i} \sum_{j=1}^{n_i} \eta_{ij}^2 - (\bar{\eta}_i)^2. \quad (3)_6$$

Аналогічно доведенню теореми про властивості вибірок із нормального розподілу, за допомогою лемми Фішера встановлюємо, що

$$\sum_{j=1}^{n_i} (\eta_{ij} - \bar{\eta}_i)^2 = \sum_{j=1}^{n_i} \eta_{ij}^2 - (\sqrt{n_i} \bar{\eta}_i)^2 \in \chi_{n-1}^2$$

і ця величина не залежить від  $\bar{\eta}_i$ .

Визначаючи суму лівої частини за і отримуємо

$$Q_1 = \sum_{i=1}^k \sum_{j=1}^{n_i} (\eta_{ij} - \bar{\eta}_i)^2 \in \chi_{N-k}^2.$$

Зазначимо, що  $Q_1$  не залежить від  $\bar{\eta}_1, \dots, \bar{\eta}_k$ .  
Далі введемо

$$\bar{\eta} = \frac{1}{N} \sum_{i=1}^k \sum_{j=1}^{n_i} \eta_{ij} = \frac{1}{N} \sum_{i=1}^k n_i \bar{\eta}_i.$$

Тоді маємо

$$\begin{aligned} Q_2 &= \sum_{i=1}^k n_i (\bar{\eta}_i - \bar{\eta})^2 = \sum_{i=1}^k n_i \bar{\eta}_i^2 - 2\bar{\eta} \sum_{i=1}^k n_i \bar{\eta}_i + \\ &+ (\bar{\eta})^2 \sum_{i=1}^k n_i = \sum_{i=1}^k (\sqrt{n_i} \bar{\eta}_i)^2 - 2\bar{\eta} N \bar{\eta} + N \bar{\eta}^2 = \\ &= \sum_{i=1}^k (\sqrt{n_i} \bar{\eta}_i)^2 - (\sqrt{N} \bar{\eta})^2. \end{aligned}$$

Нам відомо, що  $\bar{\eta}_i \in \Phi_{0, \frac{1}{n_i}}$ , тому  $\sqrt{n_i} \bar{\eta}_i \in \Phi_{0,1}$ .

Дані маємо

(4)<sub>6</sub>

$$\sqrt{N} \bar{\eta} = \frac{\sqrt{N}}{N} \sum_{i=1}^k n_i \bar{\eta}_i = \sum_{i=1}^k \frac{\sqrt{n_i}}{\sqrt{N}} \sqrt{n_i} \bar{\eta}_i =$$

$$= \left( \frac{\sqrt{n_1}}{\sqrt{N}}, \dots, \frac{\sqrt{n_k}}{\sqrt{N}} \right) (\sqrt{n_1} \bar{\eta}_1, \dots, \sqrt{n_k} \bar{\eta}_k)^T.$$

Вектор  $\left( \frac{\sqrt{n_1}}{\sqrt{N}}, \dots, \frac{\sqrt{n_k}}{\sqrt{N}} \right)$  має довжину рівну 1, тому його завжди можна добувати до ортогональної матриці, в якій він буде першим рядком. Застосуємо йому Фішера і отримаємо, що

$$Q_2 = \sum_{i=1}^k (\sqrt{n_i} \bar{\eta}_i)^2 - (\sqrt{N} \bar{\eta})^2 \in \chi^2_{k-1}.$$

Через те, що  $Q_1$  і  $Q_2$  незалежні, випакова вершина

$$\frac{\frac{Q_2}{k-1}}{\frac{Q_1}{(N-k)}} \quad \text{розподілена за законом Фішера}$$

$F_{k-1, N-k}$

Наразі перейдемо до позитивних спостережень.

$$\eta_{ij} - \bar{\eta}_i = \frac{\xi_{ij} - \alpha_i}{\sigma} - \frac{\bar{\xi}_i - \alpha_i}{\sigma} = \frac{\xi_{ij} - \bar{\xi}_i}{\sigma},$$

тому

$$Q_1 = \frac{1}{\sigma^2} \sum_{i=1}^k \sum_{j=1}^{n_i} (\xi_{ij} - \bar{\xi}_i)^2.$$



Дані припустимо, що  $H_1$  правильна, (5)<sub>6</sub>  
тобто  $\alpha_1 = \alpha_2 = \dots = \alpha_k = \alpha$ . Тоді маємо

$$\bar{\eta} = \frac{1}{N} \sum_{i=1}^k \sum_{j=1}^{n_i} \left( \frac{\xi_{ij} - \alpha_i}{\sigma} \right) = \frac{\bar{\xi} - \alpha}{\sigma}.$$

Тоді

$$Q_2 = \sum_{i=1}^k n_i \left( \frac{\bar{\xi}_i - \alpha}{\sigma} - \frac{\bar{\xi} - \alpha}{\sigma} \right)^2$$

$$= \frac{1}{\sigma^2} \sum_{i=1}^k n_i (\bar{\xi}_i - \bar{\xi})^2.$$

Отже, якщо справедлива гіпотеза  $H_1$ , то

$$(*) \quad \sum_{\text{згорта}} = \frac{Q_2 / (k-1)}{Q_1 / (N-k)} = \frac{(N-k) \sum_{i=1}^k n_i (\bar{\xi}_i - \bar{\xi})^2}{(k-1) \sum_{i=1}^k \sum_{j=1}^{n_i} (\xi_{ij} - \bar{\xi}_i)^2} \in$$

$$\in F_{k-1, N-k}.$$

Таким чином теорема доведена.

Дані перейдемо до побудови критерію. У виразі (\*) для  $\sum$  саме значення з'являється до систематичних відхилень між вибірками, тому ми реагуватимемо на великі значення  $\sum$ . За таблицею розподілу  $F_{k-1, N-k}$  знаходимо число  $q > 0$  таке, що  $F_{k-1, N-k}(q) = 1 - \varepsilon$ . Іншими словами, якщо правильна гіпотеза  $H_1$ , то подія  $\{\sum \geq q\}$  мало ймовірна. Тоді відхидаємо  $H_1$ , якщо  $\sum \geq q$ , і приймаємо гіпотезу в протилежному випадку.

При цьому  $\beta_1 = P_1(\sum \geq q) = \varepsilon$ .



## Задачі лінійної регресії:

(6)

Постановка задачі:

Припустимо, що в результаті повторень  $n$  разів експерименту отримали вибірку  $(\eta_1, \dots, \eta_n)$ . Також відомо, що значення величини  $\eta$ , що спостерігається, лінійно залежить від лійкоєв зв'язаних невиннових числових факторів  $x_1, \dots, x_k$ , та ще від деякого виннового фактора, прийнятого його повільності винновими потребами в роботі вимірювальних приладів, або його прийнятого закладено в основі експерименту. Інакше вираз

$$\eta = \theta_1 x_1 + \dots + \theta_k x_k + \varepsilon,$$

назвемо основним співвідношенням. Величини  $x_1, \dots, x_k$  можуть набувати різних значень у кожній експерименті. Невідомі коефіцієнти залежності  $\theta_1, \dots, \theta_k$ . Визначення цих коефіцієнтів становить основну задачу. Це задача буде б проста, аби не заважали випадкові відхилення. Згідно з експериментом за умови різних значень  $x_1, \dots, x_k$  отримувемо спостереження

$$\eta_1 = \theta_1 x_{11} + \dots + \theta_k x_{1k} + \varepsilon_1$$

$$\eta_2 = \theta_1 x_{21} + \dots + \theta_k x_{2k} + \varepsilon_2$$

...

$$\eta_n = \theta_1 x_{n1} + \dots + \theta_k x_{nk} + \varepsilon_n,$$

Необхідно здійснювати  $n > k$  спостережень, інакше не можливо добре оцінити всі коефіцієнти.



Припускається, що випадкові величини  $\varepsilon_1, \dots, \varepsilon_n$  незалежні і <sup>④</sup> <sup>⑥</sup> однаково розподілені. Також  $M\varepsilon_i = 0$ , дисперсія  $D\varepsilon_i = \sigma^2$  згідно припущення незалежності. Залишилося отримати вище співвідношення у векторному вигляді. Нехай

$$\eta = \begin{pmatrix} \eta_1 \\ \eta_2 \\ \vdots \\ \eta_n \end{pmatrix}, \quad X = \begin{pmatrix} x_{11} & x_{12} & \dots & x_{1k} \\ x_{21} & x_{22} & \dots & x_{2k} \\ \dots & \dots & \dots & \dots \\ x_{n1} & x_{n2} & \dots & x_{nk} \end{pmatrix},$$

$$\theta = \begin{pmatrix} \theta_1 \\ \theta_2 \\ \vdots \\ \theta_k \end{pmatrix}, \quad \varepsilon = \begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{pmatrix},$$

тоді маємо співвідношення

$$\eta = X\theta + \varepsilon. \quad (*)$$

Матриця  $X$  називається <sup>регресором</sup> регресором, вона складається із відомих нам чисел, які ми задали в процесі здійснення експерименту. Регресор має  $n$  рядків і  $k$  стовпців, його елементи вибираються так, щоб стовпці були лінійно незалежними. Випадковий вектор  $\varepsilon$  насправді присутній в цих співвідношеннях, але його значення не відомі. Вектор  $\eta$  називається відгуком, він складається із випадкових величин, що спостерігаються нами. Наявність  $\theta$  – вектор невідомих параметрів, які мають бути оцінені.

Зазначимо, що не відміну від попередньо викладеного, тут ми маємо справу з вибіркою, яка складається із фізично розподілених спостережень,



через те, що

(8)<sub>6</sub>

$$M\eta_i = \theta_1 x_{i1} + \dots + \theta_k x_{ik}$$

залежить від  $i$ ,

Трава застала основною співвідношенням (\*) лінійно залежить від певних параметрів  $\theta_1, \dots, \theta_k$  тому говоримо про задачу лінійної регресії:

Історично склалося так, що термін "регресія" не відбиває суті проблеми. Тут підійшла б назва "статистичне дослідження залежностей".

Окресливши виразом (\*) так постановку задачі. Нехай маємо набір функцій  $\psi_1(t), \dots, \psi_k(t)$ , а основне співвідношення має вигляд:

$$\eta = \theta_1 \psi_1(t) + \dots + \theta_k \psi_k(t) + \varepsilon,$$

Змінна  $t$  може інтерпретуватися як час або температура. Згідно з цим експеримент за умови  $t = t_1, \dots, t_n$ , отримують спостереження

$$\eta_i = \theta_1 \psi_1(t_i) + \dots + \theta_k \psi_k(t_i) + \varepsilon_i, \quad i = 1, \dots, n,$$

тобто  $x_{ij} = \psi_j(t_i)$ . Наприклад, можна взяти

$$\psi_1(t) = 1, \quad \psi_2(t) = t, \quad \dots, \quad \psi_k(t) = t^{k-1}$$


і тоді основне співвідношення набуде вигляду:

$$\eta = \theta_1 + \theta_2 t + \dots + \theta_k t^{k-1} + \varepsilon.$$



У цьому випадку задача має просту геометричну інтерпретацію.


⑨в



Числа  $\theta_1, \dots, \theta_k$  є коефіцієнтами полінома. Задача полягає в тому, що підібрати їх так, щоб графік полінома найкращим чином наближав отриману сукупність точок  $(t_1, \eta_1), (t_2, \eta_2), \dots, (t_n, \eta_n)$ .

В окремому випадку, коли  $k=2$ , маємо справу з простою регресією, в інших випадках регресія називається нелинійною.

Приклад. Припустимо, що ми вивчаємо залежність розширності речовини в емісії рідини від температури цієї рідини. Позначимо температуру літнього  $t$  і збільшимо вимірювання розширності за різних температур. Отримані дані (див. графік) вказують на лінійну залежність.



$$\eta_i = \theta_1 + \theta_2 t_i + \varepsilon_i, \quad i = 1, \dots, n.$$

Задача полягає в обчисленні певного набору параметрів  $\theta_1$  і  $\theta_2$ , що визначають цю залежність.

## Л7. Метод найменших квадратів. ⑦

Оцінивши невідомі параметри  $\theta_1, \dots, \theta_k$  будемо знаходити методом найменших квадратів.


Введемо відповідні позначення

$$S(\theta) = \sum_{i=1}^n (\eta_i - \theta_1 x_{i1} - \dots - \theta_k x_{ik})^2 =$$
$$= |\eta - X\theta|^2,$$

Оцінкою методом найменших квадратів (МНК-оцінкою) називається те значення  $\theta = \theta^*$ , за якого  $S(\theta)$  досягає мінімального значення:

$$S(\theta^*) = \min_{\theta} S(\theta).$$

Якщо звернутися до розглянутої вище графічної ілюстрації, ми бачимо, що значення  $\theta_1, \dots, \theta_k$  підбираються так, щоб мінімальною була сума квадратів довжин вертикальних відрізків, які сполучають точки  $(t_i, \eta_i)$  з відповідними точками на кривій.



Знаходять МНК-оцінку можливо різними способами. Один із них полягає у розв'язанні системи так званих нормальних рівнянь:



$$\frac{\partial S(\theta)}{\partial \theta_j} = 0, j = 1, \dots, k,$$


(2)<sub>7</sub>

що досить не просто. Спробуємо знайти  
оптиму із геометричних міркувань.

Позначимо через  $X_1, \dots, X_k$  стовпні матриці  $X$ .  
Це лінійно незалежні вектори в  $\mathbb{R}^n$ . Через те,  
що  $k < n$ , ці вектори породжують в  $\mathbb{R}^n$  підпростір  $\mathbb{R}^k$ .  
Будь-яке лінійне комбінування цих векторів  
знову належить тому ж  $\mathbb{R}^k$ , тобто для  $\theta$

$$X\theta = X_1\theta_1 + \dots + X_k\theta_k \in \mathbb{R}^k$$

В тому жекі  $X\theta^* \in \mathbb{R}^k$ . Простежуємо все це  
на рисунку, коли  $n=3$ , а  $k=2$ .



У відповідності з методом найменших квадратів  
потрібно знайти таке значення  $\theta = \theta^*$ ,  
за якого довжина вектора  $r = X\theta^*$  буде  
мінімальною. Цей вектор на рисунку зобра-  
жений пунктиром. Зрозуміло, що його довжина  
мінімальна, якщо він ортогональний площині,  
а також гілок і векторам, що породжують цю  
площину. Запишемо цей висновок для загального  
випадку:

$$r - X\theta^* \perp X_j, j = 1, \dots, k.$$

Інакше це можна записати так:

$$X^T(r - X\theta^*) = 0,$$

де  $0$  - це нульовий вектор розмірності  $(3)_7$   
 $k$ . Звідси знаходимо, що

$$X^T \eta = X^T X \theta^*$$

Квадратна матриця  $X^T X \in \mathbb{R}^{n \times n}$  є невід'ємною.  
 Додатково отриману рівність зліва на  $(X^T X)^{-1}$ ,  
 отримаємо МНК-оцінку

$$\theta^* = (X^T X)^{-1} X^T \eta.$$

Припустимо додатково, що вектори  $x_1, \dots, x_k$   
 ортогональні. У цьому випадку задача лінійної  
 регресії значно спрощується, зокрема мат-  
 риця  $X^T X$  стає діагональною:

$$X^T X = \begin{pmatrix} (x_1, x_1) & 0 & \dots & 0 \\ 0 & (x_2, x_2) & \dots & 0 \\ \dots & \dots & \dots & \dots \\ 0 & 0 & \dots & (x_k, x_k) \end{pmatrix};$$

$(X^T X)^{-1}$  також буде діагональною;

$$(X^T X)^{-1} = \begin{pmatrix} (x_1, x_1)^{-1} & 0 & \dots & 0 \\ 0 & (x_2, x_2)^{-1} & \dots & 0 \\ \dots & \dots & \dots & \dots \\ 0 & 0 & \dots & (x_k, x_k)^{-1} \end{pmatrix}.$$

Якщо додати до останньої матриці вектор

$$X^T \eta = \begin{pmatrix} (x_1, \eta) \\ (x_2, \eta) \\ \dots \\ (x_k, \eta) \end{pmatrix}$$



то отримаємо просте вираження для (4)  
компонент МНК-оцінки  $\theta^*$ :

$$\theta_i^* = \frac{(X_i, \eta)}{(X_i, X_i)}, \quad i=1, \dots, k.$$

### Довіри інтервали та перевірка гіпотез

Після визначення серією незалежних параметрів  
природно задати питання можливості  
побудови довірчих інтервалів та перевірки гіпо-  
тез. Для цього необхідно інформація про розподіл  
випадкових величин  $\varepsilon_i$ .

Припустимо, що випадкові величини  $\varepsilon_1, \dots, \varepsilon_n$   
незалежні та розподілені за законом  $\Phi, \sigma^2$ .  
В таких випадках маємо зв'язу корреляційної  
регресії:

Теорема Нехай всі  $\varepsilon_i$  незалежні і розподілені  
за законом  $\Phi, \sigma^2$ . Тоді оцінка методом максималь-  
ної вірогідності (ММВ-оцінка) і оцінка методом  
найменших квадратів (МНК-оцінка) для параметра  
 $\theta$  співпадають.

Доведення. Запишемо функцію вірогідності  
вибірки. Не зважаючи на те, що спостереження  
тих розподілені не одначово, принцип залишається  
таким же.

$$\begin{aligned} f(\theta, \sigma^2, \eta) &= (2\pi\sigma^2)^{-\frac{n}{2}} \exp \left\{ -\frac{1}{2\sigma^2} \sum_{i=1}^n (\eta_i - \theta_1 x_{i1} - \dots - \theta_k x_{ik})^2 \right\} \\ &= (2\pi\sigma^2)^{-\frac{n}{2}} \exp \left\{ -\frac{1}{2\sigma^2} S(\theta) \right\}. \end{aligned}$$



(5)

З даного запису витікає, що досліджувати функцію вірогідності на максимум — це те ж саме, що досліджувати  $S(\theta)$  на мінімум. Теорему доведемо.

Якщо маємо функцію вірогідності, знайдемо ММВ-оцінку для  $\sigma^2$ . Маємо

$$\ell(\theta, \sigma^2, \eta) = -\frac{n}{2} \ln 2\pi - \frac{n}{2} \ln \sigma^2 - \frac{1}{2\sigma^2} |\eta - X\theta|^2,$$

$$\frac{\partial \ell(\theta, \sigma^2, \eta)}{\partial (\sigma^2)} = -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4} |\eta - X\theta|^2 = 0,$$

звідси отримуємо ММВ-оцінку для  $\sigma^2$

$$(\sigma^2)^* = \frac{|\eta - X\theta^*|^2}{n}.$$

Нижче наведемо без доведення теорему, яка встановлює ймовірнісні властивості оцінок невідомих параметрів в задачах нормальної регресії.

Теорема Нехай всі  $\varepsilon_i$  незалежні і розподілені за законом  $\Phi_0, \sigma^2$ . Тоді:

1) ММВ-оцінка  $\theta^*$  має багатовимірний нормальний розподіл, причому

$$M\theta^* = \theta, \quad C(\theta^*) = \sigma^2 (X^T X)^{-1};$$

2)  $\frac{|\eta - X\theta^*|^2}{\sigma^2} \in \chi_{n-1}^2;$

3)  $\theta^*$  та  $|\eta - X\theta^*|^2$  незалежні.



Настіжок 1. Оцінка

⑥<sub>7</sub>

$$\hat{\sigma}^2 = \frac{1}{n-k} |v - X\theta^*|^2$$

є незміщеною для  $\sigma^2$ .

Доведення. У зв'язності до 2) твердження  
сформульованої теореми, випадкова величина

$$\frac{|v - X\theta^*|^2}{\sigma^2} \text{ розкладається як } Z_1^2 + \dots + Z_{n-k}^2,$$

де всі  $Z_i$  незалежні і розподілені за законом  
 $\Phi_{0,1}$ , тому маємо

$$M\left(\frac{|v - X\theta^*|^2}{\sigma^2}\right) = M(Z_1^2 + \dots + Z_{n-k}^2) = n-k,$$

тобто

$$M\left(\frac{|v - X\theta^*|^2}{n-k}\right) = \sigma^2$$

Звідси випливає, крім іншого, що знайдена  
вище ММВ-оцінка  $(\sigma^2)^*$  є зміщеною.

Настіжок 2. Якщо стовпні регресора  $X_1, \dots, X_k$   
ортонормальні, то матриця  $C(\theta^*) = \sigma^2(X^T X)^{-1}$   
діагональна і компоненти оцінки  $\theta_1^*, \dots, \theta_k^*$  неза-  
лежні. При цьому

$$\theta_i^* \in \Phi_{\theta_i, \frac{\sigma^2}{|X_i|^2}}.$$

Це твердження відрізняється з властивостей  
багатовимірною нормального розподілу.

Настіжок 3. Якщо стовпці регресора

(7)<sub>4</sub>

$X_1, \dots, X_k$  ортогональні, то

$$\frac{(\theta_i^* - \theta_i) |X_i|}{\sigma} \cdot \sqrt{\frac{1}{n-k} \frac{|1 - X\theta^*|^2}{\sigma^2}} \geq \\ = \frac{(\theta_i^* - \theta_i) |X_i| \sqrt{n-k}}{|1 - X\theta^*|} \in T_{n-k}.$$

Тоді перейдемо до побудови довірчих інтервалів.

1. Довірчий інтервал для  $\sigma^2$ . З таблиці розподілу  $\chi^2_{n-k}$  знаходимо числа  $q_1$  і  $q_2$  такі, що

$$\chi^2_{n-k}(q_1) = \frac{\varepsilon}{2}, \quad \chi^2_{n-k}(q_2) = 1 - \frac{\varepsilon}{2}.$$

Тоді, у відповідності з наслідком 1,

$$P\left(q_1 < \frac{|1 - X\theta^*|^2}{\sigma^2} < q_2\right) = \chi^2_{n-k}(q_2) - \chi^2_{n-k}(q_1) = 1 - \varepsilon,$$

звідси випливає, що

$$P\left(\frac{|1 - X\theta^*|^2}{q_2} < \sigma^2 < \frac{|1 - X\theta^*|^2}{q_1}\right) = 1 - \varepsilon.$$

Тоді припускаємо, що стовпці регресора  $X_1, \dots, X_k$  ортогональні.

2. Довірчий інтервал для  $\theta_i$  за умови, що  $\sigma^2$  відома.

Застосуємо факт, що  $\frac{(\theta_i^* - \theta_i) |X_i|}{\sigma} \in \Phi_{0,1}$ .



Нехай число  $q$  таке, що  $\Phi_{0,1}(-q) = \frac{\varepsilon}{2}$ , (8)  
тоді маємо

$$P\left(-q < \frac{(\theta_i^* - \theta_i)|X_i|}{\sigma} < q\right) = \Phi_{0,1}(q) - \Phi_{0,1}(-q) = 1 - \varepsilon,$$

тобто

$$P\left(\theta_i^* - \frac{q\sigma}{|X_i|} < \theta_i < \theta_i^* + \frac{q\sigma}{|X_i|}\right) = 1 - \varepsilon.$$

3. Довірчий інтервал для  $\theta_i$  за умови, що  $\sigma^2$  невідомо.

Застосовуючи лемму 3 і знайдемо з таблиць  
число  $q$  таке, що  $T_{n-k}(-q) = \frac{\varepsilon}{2}$ .

Тоді

$$P\left(-q < \frac{(\theta_i^* - \theta_i)|X_i|\sqrt{n-k}}{|\eta - X\theta^*|} < q\right) = T_{n-k}(q) -$$

$$- T_{n-k}(-q) = 1 - \varepsilon$$

після відповідних перетворень отримаємо довір-  
чий інтервал

$$P\left(\theta_i^* - \frac{q|\eta - X\theta^*|}{|X_i|\sqrt{n-k}} < \theta_i < \theta_i^* + \frac{q|\eta - X\theta^*|}{|X_i|\sqrt{n-k}}\right) = 1 - \varepsilon,$$

Побудова довірчих інтервалів надає можливість  
перевірити гіпотезу  $H_0$  відповідності з виголо-  
шеною раніше констатцією. Наприклад, для  
перевірки гіпотези  $H_1: \theta_i = C$  проти гіпотези  
 $H_2: \theta_i \neq C$  за умови невідомої дисперсії  $\sigma^2$

берем критичную точку

⑨<sub>7</sub>

$$K = \left\{ (\eta_1, \dots, \eta_n) : C \notin \left( \theta_i^* - \frac{q|\eta - X\theta^*|}{|X_i|\sqrt{n-k}}, \theta_i^* + \frac{q|\eta - X\theta^*|}{|X_i|\sqrt{n-k}} \right) \right\}.$$

Тоги

$$\beta_1 = P_1((\eta_1, \dots, \eta_n) \in K) = \varepsilon.$$