

Метод найменших квадратів.

①
15

5. Передбачається, що залежність ознаки Y від ознаки X має такий вигляд

$$y = f(x, \alpha_1, \alpha_2, \dots, \alpha_m)$$

де x - значення ознаки X ; y - значення ознаки Y ;

$\alpha_1, \alpha_2, \dots, \alpha_m$ - параметри, які належать визначенню, та, що за результатами експерименту отримані такі експериментальні дані:

*)	Значення ознаки X	x_1	x_2	\dots	x_i	\dots	x_n
	Значення ознаки Y	y_1	y_2	\dots	y_i	\dots	y_n

Метод найменших квадратів створює, що найбільш вірніше значення параметрів $\alpha_1, \alpha_2, \dots, \alpha_m$ дає мінімум функції

$$S = \sum_{i=1}^n [y_i - f(x_i, \alpha_1, \alpha_2, \dots, \alpha_m)]^2$$

Коли $f(x, \alpha_1, \alpha_2, \dots, \alpha_m)$ ~~не~~ ^{має} неперервні частинні похідні за усіма своїми параметрами, то необхідна умова мінімуму функції S складає систему m рівнянь з m невідомими:

$$(*, *) \quad \frac{\partial S}{\partial \alpha_1} = 0; \quad \frac{\partial S}{\partial \alpha_2} = 0; \quad \dots; \quad \frac{\partial S}{\partial \alpha_m} = 0.$$

Визначення функціональної залежності між ознаками Y та X на основі виспостережуваних даних $(*)$ називають вирівнюванням експериментальних даних вздовж кривої $y = f(x, \alpha_1, \alpha_2, \dots, \alpha_m)$.

(2)

Якщо $f(x, \alpha_1, \alpha_2, \dots, \alpha_m) = \alpha_1 x + \alpha_2$ то
 заданого кривою буде прямию ліній $y = \alpha_1 x + \alpha_2$.
 У цьому випадку система (x, y) може бути
 перетворена у так звану нормальну систему
 методом найменших квадратів за умови
 вирівнювання за прямою:

$$\begin{cases} \alpha_1 \sum_{i=1}^n x_i^2 + \alpha_2 \sum_{i=1}^n x_i = \sum_{i=1}^n x_i y_i; \\ \alpha_1 \sum_{i=1}^n x_i + \alpha_2 n = \sum_{i=1}^n y_i. \end{cases}$$

Система (x, y) при вирівнюванні згідно з
 за параболою $y = \alpha_1 x^2 + \alpha_2 x + \alpha_3$ може бути
 перетворена до такого вигляду:

$$\begin{cases} \alpha_1 \sum_{i=1}^n x_i^4 + \alpha_2 \sum_{i=1}^n x_i^3 + \alpha_3 \sum_{i=1}^n x_i^2 = \sum_{i=1}^n x_i^2 y_i; \\ \alpha_1 \sum_{i=1}^n x_i^3 + \alpha_2 \sum_{i=1}^n x_i^2 + \alpha_3 \sum_{i=1}^n x_i = \sum_{i=1}^n x_i y_i; \\ \alpha_1 \sum_{i=1}^n x_i^2 + \alpha_2 \sum_{i=1}^n x_i + \alpha_3 n = \sum_{i=1}^n y_i. \end{cases}$$

Лінійна кореляційна залежність

Стверджується, що зв'язки X та Y знаходяться
 в кореляційній залежності, якщо кожному значен-
 ню одного з них відповідає деякий розподіл
 іншого. Кореляційна залежність ліній означає
 X та Y задають за допомогою кореляційної
 таблиці:

Кореляційна таблиця

3.

$X \backslash Y$	y_1	y_2	\dots	y_j	\dots	y_n	m_{x_i}
x_1	m_{11}	m_{12}	\dots	m_{1j}	\dots	m_{1n}	m_{x1}
x_2	m_{21}	m_{22}	\dots	m_{2j}	\dots	m_{2n}	m_{x2}
\vdots	\vdots	\vdots	\vdots	\vdots	\vdots	\vdots	\vdots
x_i	m_{i1}	m_{i2}	\dots	m_{ij}	\dots	m_{in}	m_{xi}
\vdots	\vdots	\vdots	\vdots	\vdots	\vdots	\vdots	\vdots
x_k	m_{k1}	m_{k2}	\dots	m_{kj}	\dots	m_{kn}	m_{xk}
m_y	m_{y1}	m_{y2}	\dots	m_{yj}	\dots	m_{yn}	N

У цій таблиці $x_1, x_2, \dots, x_i, \dots, x_k$; $y_1, y_2, \dots, y_j, \dots, y_n$ — середні інтервали або значення ознак X та Y , а $m_{x1}, m_{x2}, \dots, m_{xi}, \dots, m_{xk}$; $m_{y1}, m_{y2}, \dots, m_{yj}, \dots, m_{yn}$ — відповідні частоти; m_{ij} — частота, з якою зустрічається пара (x_i, y_j) ; $N = \sum_{i=1}^k \sum_{j=1}^n m_{ij}$.

Кореляційна залежність між ознаками Y та X може бути замінена функціональною, якщо кожному значенню ознаки X поставити у відповідність умовне середнє ознаки Y , тобто для $X = x_i$ поставити у відповідність величину

$$\bar{Y}_{x_i} = \frac{\sum_{j=1}^n m_{ij} y_j}{m_{xi}}$$

Якщо потім точки (x_i, \bar{Y}_{x_i}) вписати за допомогою найменших квадратів в згладжену криву $y = f(x, \alpha_1, \alpha_2, \dots, \alpha_n)$, то отримаємо

називається лінійною регресією y на x , (4)
а її рівняння - рівнянням регресії y на x .
Аналогічно визначається лінійна регресія x на y .
Найпростішими і найважливішими ви-
падами кривих регресії є прямі лінії.

Кутовий коефіцієнт прямої регресії y на x
(x на y) називають коефіцієнтом регресії
 y на x (x на y) і позначають так $\rho_{y/x}$ ($\rho_{x/y}$).
Коефіцієнти регресії можуть бути розрахо-
вані за формулами:

$$\rho_{y/x} = \frac{\overline{XY} - \bar{X}\bar{Y}}{\sigma_x^2}; \quad \rho_{x/y} = \frac{\overline{XY} - \bar{X}\bar{Y}}{\sigma_y^2},$$

де $\overline{XY} = \frac{\sum_{i=1}^k \sum_{j=1}^n m_{ij} x_i y_j}{N}$ - середнє значення до-
бутку ознак X та Y ; \bar{X} і \bar{Y} - їх середні зна-
чення, а σ_x^2 та σ_y^2 - їх дисперсії.

Рівняння прямої регресії мають ~~вигляд~~
вигляд:

$$y - \bar{Y} = \rho_{y/x} (x - \bar{X});$$

$$x - \bar{X} = \rho_{x/y} (y - \bar{Y}).$$

Коефіцієнт лінійної кореляції ознак X та Y
називається величина

$$r = r(X, Y) = \frac{\overline{XY} - \bar{X}\bar{Y}}{\sigma_x \sigma_y} = \pm \sqrt{\rho_{y/x} \rho_{x/y}}.$$

Коефіцієнт лінійної кореляції r (5)
характеризується такими властивостями:

1) $-1 \leq r \leq 1$;

2) $r[\alpha(X-x_0), \beta(Y-y_0)] = r(X, Y)$ ($\alpha > 0, \beta > 0$);

3) якщо $r(X, Y) = \pm 1$, то між ознаками X і Y існує лінійна функціональна залежність (коли $r = 1$ - пряма залежність, а коли $r = -1$ - зворотна залежність);

4) якщо $r(X, Y) = 0$, то між ознаками X та Y відсутня лінійна кореляційна залежність;

5) $r_{y/x} = r \frac{\sigma_y}{\sigma_x}$ і $r_{x/y} = r \frac{\sigma_x}{\sigma_y}$.

Квадрат коефіцієнта лінійної кореляції дає коефіцієнт детермінації, який вимірює долю варіації Y , яка пояснюється впливом ознаки X , і навпаки.

На практиці про розподіл ознак X та Y в генеральній сукупності визначають за даними вибірки. За цими даними можливо знайти вибірочний коефіцієнт лінійної кореляції r_B , який є випадковою величиною. За умови достатньо великої об'єму вибірки $r_B \approx r$. Якщо розподіл ознак X та Y досить близький до нормального, то можливо надійніше вважати r_B такою нормальною випадковою величиною, середнє квадратичне відхилення якої дорівнює

$$\frac{1-r^2}{\sqrt{N}}, \text{ де } N - \text{об'єм вибірки.}$$

Трисклад розв'язання задачі:

(6)

Задача 1.

Компанія-перевізник провела статистичне дослідження на основних маршрутах і одержала залежність між вартістю перевезення ξ (в умовних одиницях за 1 км) і довжиною маршруту η (тис. км). Результати дослідження наведені в таблиці:


Значення вартості x_i	1	3	5	7	9	11	13	15	16	17
Довжина маршруту y_i	12	11,4	10,6	10,1	9,5	8,4	8	7,5	7,1	6,6

В задачі потрібно

- 1) встановити форму залежності між ξ і η ,
- 2) знайти рівняння лінійної регресії η на ξ та ξ на η ;
- 3) обчислити коефіцієнт кореляції вибірки r та оцінити силу лінійного зв'язку між ξ та η .

Розв'язок.

- 1) Для візуалізації залежності ознак ξ та η графічно зобразимо точки (x_i, y_i) .



2) Зв'язок між ознаками ξ та η , який вирається може бути виражений рівнянням прямої лінійної регресії η на ξ : $\bar{y}_x = ax + b$.
 Для обчислення параметрів a і b та коефіцієнта кореляції складено розрахункові таблиці:

(*)	x_i	1	3	5	7	9	11	13	15	16	17	$\sum x_i$ 97
	y_i	12	11,4	10,6	10,1	9,5	8,4	8	7,5	7,1	6,6	91,2
	x_i^2	1	9	25	49	81	121	169	225	256	289	1225
	y_i^2	144	129,96	112,36	102,01	90,25	70,56	64	56,25	50,41	43,56	844,3
	$x_i y_i$	12	34,2	53	70,7	85,5	92,4	104	112,5	113,6	108,6	783,5

Знайдемо рівняння лінійної регресії η на ξ .

$$\bar{y}_x = ax + b$$

Застосуємо метод найменших квадратів і складемо систему рівнянь для визначення параметрів a і b .

$$\begin{cases} a \sum_{i=1}^n x_i^2 + b \sum_{i=1}^n x_i = \sum_{i=1}^n x_i y_i \\ a \sum_{i=1}^n x_i + b n = \sum_{i=1}^n y_i \end{cases}$$

$$n=10$$

Підставимо значення із таблиці (*) і отримувемо систему рівнянь:

$$\begin{cases} 1225 \cdot a + 97 \cdot b = 783,5 \\ 97 \cdot a + 10 \cdot b = 91,2 \end{cases}$$

$$a = \frac{783,5 - 97b}{1225}, \quad 97 \frac{783,5 - 97b}{1225} + 10b = 91,2 \Rightarrow$$

$$\Rightarrow 97(0,64 - 0,08b) + 10b = 91,2 \Rightarrow b = \frac{29,12}{2,24} = 13;$$

$$a = \frac{783,5 - 97 \cdot 13}{1225} = \frac{783,5 - 1261}{1225} = \frac{-477,5}{1225} = -0,4;$$

$$\bar{y}_x = -0,4x + 13.$$

Знайдемо рівняння лінійної регресії ξ на η (8)

$$\bar{x}_y = ay + b.$$

Для визначення параметрів a та b за методом найменших квадратів запишемо відповідну систему рівнянь.

$$\begin{cases} a \sum_{i=1}^n y_i^2 + b \sum_{i=1}^n y_i = \sum_{i=1}^n x_i y_i \\ a \sum_{i=1}^n y_i + b n = \sum_{i=1}^n x_i \end{cases}$$

Із таблиці (*) підставляємо розраховані дані. Отримуємо таку систему рівнянь:

$$\begin{cases} 844,3 \cdot a + 91,2 b = 783,5 \\ 91,2 a + 10 b = 97 \end{cases}$$

Розв'яжемо систему рівнянь.

$$a = \frac{783,5 - 91,2 b}{844,3} \Rightarrow 91,2(0,93 - 0,1b) + 10b = 97;$$
$$\Rightarrow 84,8 - 9,12b + 10b = 97; \Rightarrow 0,88b = 12,2 \Rightarrow b = \frac{12,2}{0,88} =$$
$$= 13,9 \approx 14$$

$$a = \frac{783,5 - 91,2 \cdot 13,9}{844,3} = \frac{783,5 - 1267,68}{844,3} = \frac{-484,18}{844,3} =$$
$$= -0,57; \Rightarrow a = -0,57, b = 14 \quad \bar{x}_y = -0,57x + 14.$$

3) Обчислимо коефіцієнт кореляції r вибірки.

Коефіцієнт кореляції визначається за формулою

$$r(\xi, \eta) = \frac{\bar{\xi}\eta - \bar{\xi} \cdot \bar{\eta}}{\sigma_{\xi} \cdot \sigma_{\eta}};$$

Необхідно знайти вибіркові середні добутку ознак ξ та η $\bar{\xi}\eta = \frac{1}{n} \sum_{i=1}^n x_i y_i$; середні вибіркові

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i; \quad \bar{y} = \frac{1}{n} \sum_{i=1}^n y_i; \quad (9)$$

та вибіркові середньо-квадратичні відхилення

$$\sigma_x = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2}; \quad \sigma_y = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^2}$$

Застосуємо обчислені значення із таблиць (*) і знайдемо вибіркові середні:

$$\bar{x}y = \frac{1}{n} \sum_{i=1}^n x_i y_i = \frac{1}{10} \cdot 783,5 = 78,35;$$

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i = \frac{1}{10} \cdot 97 = 9,7; \quad \bar{y} = \frac{1}{n} \sum_{i=1}^n y_i = \frac{91,2}{10} = 9,12;$$

Для визначення σ_x і σ_y складемо таблицю где $(x_i - \bar{x})^2$ та $(y_i - \bar{y})^2$

$(x_i - \bar{x})^2$	75,69	44,89	22,09	7,29	0,49	1,69	2,89	3,61	5,29
$(y_i - \bar{y})^2$	8,3	5,2	2,2	0,77	0,14	0,52	1,25	2,62	6,35

Застосовуючи значення із таблиць (*, *) знайдемо σ_x та σ_y

$$\sigma_x = \left[\frac{1}{9} (75,69 + 44,89 + 22,09 + 7,29 + 0,49 + 1,69 + 10,89 + 28,09 + 39,69 + 53,29) \right]^{1/2} = \sqrt{\frac{284,1}{9}} = 5,61; \quad \sigma_x = 5,61$$

$$\sigma_y = \left[\frac{1}{9} (8,3 + 5,2 + 2,2 + 0,77 + 0,14 + 0,52 + 1,25 + 2,62 + 4,08 + 6,35) \right]^{1/2} = \sqrt{\frac{34,43}{9}} = 1,87$$

$$\sigma_y = 1,87.$$

$$r(\xi, \eta) = \frac{78,35 - 9,7 \cdot 9,12}{5,61 \cdot 1,87} = \frac{78,35 - 88,46}{10,49} =$$

$$= \frac{-10,11}{10,49} = -0,96$$

Ознаки ξ та η , віз'яють корелювані. Це
визначається тим, що коли ознака ξ зростає,
ознака η спадає. Значення r вказує на те,
що кореляція ознак ξ та η висока.